

Введение в машинное обучение

Линейная регрессия

Задача

Восстановить (сложную) зависимость по конечному числу примеров

Пример задачи

Предсказать цену на квартиру по ее характеристикам

- ▶ площадь
- ▶ расположение (район, расстояние до метро)
- ▶ ремонт, наличие мебели
- ▶ и т.д.

Обозначения

- ▶ x - объект, *sample* - для чего хотим делать предсказания (квартира)
 - ▶ \mathbb{X} - пространство всех возможных объектов (все квартиры на свете)
 - ▶ y - ответ, целевая переменная, *target* - что предсказываем (цена)
 - ▶ \mathbb{Y} - пространство ответов - все возможные значения ответа ($\in \mathbb{R}, \geq 0$)
-
- ▶ $X = \{(x_1, y_1), \dots, (x_\ell, y_\ell)\}$ - обучающая выборка: все пары (квартира - ее цена)
 - ▶ ℓ - размер обучающей выборки

Представление объектов

- ▶ Как сделать объекты машиночитаемыми?
- ▶ Представить в виде набора признаков - числовых характеристик.
- ▶ Каждый объект - вектор чисел $x = (x^1, \dots, x^d)$
- ▶ d - количество признаков
- ▶ Обучающая выборка - матрица размера $\ell \times d$
- ▶ Каждая строка - объект, каждый столбец - признак.


Линейная регрессия

- ▶ Функция, которая отображает \mathbb{X} в \mathbb{Y}
- ▶ Хотим засунуть в нее вектор признаков объекта x и получить на выходе соответствующий ему ответ y
- ▶ Сводится к суммированию значений признаков x с некоторыми коэффициентами (весами) w + свободный коэффициент w_0 :

$$a(x) = w_0 + \sum_{j=1}^d w_j x_j. \quad (1)$$

Парная регрессия

Частный случай линейной регрессии с одним признаком:



Линейная регрессия

Площадь	Расстояние до метро	Цена квартиры
100	200	10600
35	500	3500
50	100	5800

$$Price = 100S - 2Distance + 1000 \quad (2)$$

Обучение

- ▶ Обучиться = подобрать значения весов так, чтобы модель давала ответы как можно ближе к реальности.
- ▶ **Минимизация эмпирического риска** - добиться минимально возможной ошибки на обучающей выборке.
- ▶ Как измерить ошибку?

Функция потерь

- ▶ обозначается Q
- ▶ Чаще всего используется *Mean Squared Error*:

$$MSE(a, X) = \frac{1}{\ell} \sum_{i=1}^{\ell} (a(x_i) - y_i)^2. \quad (3)$$

- ▶ Среднее арифметическое квадрата разницы предсказанного ответа и реального.

Функция потерь

- Получаем задачу оптимизации (считаем, что среди признаков есть константный, и поэтому свободный коэффициент не нужен):

$$\frac{1}{\ell} \sum_{i=1}^{\ell} (\langle w, x_i \rangle - y_i)^2 \rightarrow \min_w \quad (4)$$

Методы оптимизации

- ▶ Метод Наименьших Квадратов (применим для линейной регрессии и квадратичной функции потерь)
- ▶ Градиентный спуск (общий подход)


Градиент

- ▶ Градиентом функции называется вектор ее частных производных:

$$\nabla f(x_1, \dots, x_d) = \left(\frac{\partial f}{\partial x_j} \right)_{j=1}^d \quad (5)$$

- ▶ Частная производная - производная многомерной функции по одной из переменных.
- ▶ **Градиент является направлением наискорейшего роста функции, а антиградиент (т.е. $-\nabla f$) — направлением наискорейшего убывания.**
- ▶ Причем норма (длина) градиента равна величине скорости возрастания/убывания.

Градиент



Градиентный спуск

- ▶ $W^{(0)} \leftarrow N(0, 1)$ инициализировать начальное приближение для вектора весов случайными небольшими значениями.
- ▶ for i in range(max_iter):
 - ▶ $\nabla_w Q = [\frac{\partial Q}{\partial w_0}, \frac{\partial Q}{\partial w_1}, \dots, \frac{\partial Q}{\partial w_d}]$ - посчитать градиент в точке $W = W^{(t)}$
 - ▶ $W^{(t+1)} = W^{(t)} - \alpha * \nabla_w Q$ - обновить вектор весов, сделав шаг длины α в сторону антиградиента
 - ▶ Если $\|\nabla_w Q\|_2 < \epsilon$ - если норма градиента стала меньше некоторой заданной малой величины (значение функции потерь больше (почти) не уменьшается), то мы считаем, достигли минимума и прерываем цикл
- ▶ $\alpha, \epsilon, \text{max_iter}$ - гиперпараметры, значение которых задается заранее